

# Reinforcement Learning-Based Computer Numerical Control Motion Planning with Learnable Preview Distance and Jerk-Constrained Action Projection

作者姓名<sup>a</sup>

<sup>a</sup> 某某大学/机构, 某某路, 某某市, 000000, 中国

---

## Abstract

Computer numerical control (CNC) machining requires motion planning that smooths mixed tool paths within a contour tolerance band while preserving feed efficiency and satisfying velocity, acceleration, and jerk limits. This paper proposes a structured reinforcement learning (RL) decision framework for tolerance-band CNC motion planning, where Proximal Policy Optimization (PPO) learns steering, feedrate, and preview-distance actions so that the policy can actively select the geometric perception scale needed by straight, corner-entry, corner-passing, and corner-exit phases. An interpretable kinematic constraint module (KCM) is embedded as a jerk-constrained action-projection layer, transforming unconstrained policy intentions into interpolation commands that satisfy linear and angular velocity, acceleration, and jerk bounds. Experiments on square, circular, and butterfly paths show that the proposed method generates tolerance-feasible smoothed trajectories and eliminates the jerk violations observed in a neural network controller (NNC) baseline, improving the dynamic executability of CNC motion planning under complex geometric changes.

*Keywords:* computer numerical control, reinforcement learning, learnable preview distance, jerk-constrained action projection

---

## 1. 引言

现代高端数控加工通常以 CAM 生成的离散刀具路径作为输入，复杂自由曲面和高速精密加工的加工效率、轮廓精度、表面质量和伺服平稳性由路径、进给率与轨迹规划直接决定 [1]。数控系统的运动规划任务，是在给定轮廓允差和机床运动能力约束 [2, 3] 下，把离散路径转化为可执行的插补序列；因此，运动规划已成为连接 CAM 路径和伺服执行的关键环节。

在实际加工中，大量长短直线、圆弧以及局部曲率快速变化的程序段密集交接 [4, 5]。若沿原始几何逐段插补，拐角处的切向或曲率不连续会使速度急剧变化，进而超出加速度和捷度约束 [6, 7]。因此，复杂混合路径上的核心问题从单纯跟踪给定编程轨迹，扩展为在允差范围内同时处理轨迹平滑、速度安排和运动学可执行性。

传统运动规划方法通常采用先轨迹平滑、再速度规划的串联方案 [2, 8]。轨迹平滑主要有局部拐角过渡和全局轨迹平滑两种方法。局部方法通过构造连续过渡曲线改善相邻程序段连接，如直线/圆弧混合路径运动重叠方法 [4]、曲率连续 B 样条过渡 [9]。全局方法从全局范围进行轨迹平滑，如结合控制点分配与 FIR 滤波实现短线段全局平滑 [10]，面向五轴路径提高平滑插补效率 [11]。速度规划则沿给定轨迹生成进给曲线，如 NURBS 速度规划 [2]、捷度受限轨迹生成 [6]，以及轴驱动约束前瞻的速度规划 [12]。

在串联式流程下，速度规划效果受限于已经确定的轨迹规划结果 [7]，难以反向改变已经生成的几何执行轨迹。几何轨迹确定后，在捷度约束、非平稳边界条件下的速度规划，也主要围绕提高既定轨迹提高动态可执行性 [13, 14]。前瞻窗口调度动态前瞻研究说明，固定前瞻范围也难以适配直线进给、接近拐角、过弯和离开拐角等不同阶段的几何信息需求 [12, 15]。

为解决这一问题，近年方法开始把学习策略、前方几何感知和显式约束模块引入运动规划过程。Song 等人 [12] 与 Zhong 等人 [15] 说明前方路径信息和在线前瞻调整会影响速度规划与局部几何响应；针对学习动作可能不满足安全约束的问题，Pham 等 [16] 的 OptLayer、Alshiekh 等 [17] 的 shielding、Cheng 等 [18] 的 control-barrier-function 安全控制和 Wabersich 与 Zeilinger [19] 的 predictive safety filter 均采用外部投影或过滤机制修正策略动作。Li 等人 [20] 将强化学习用于 CNC 轨迹平滑，Samsonov 等人 [21] 也表明深度表征学习和强化学习可用于 CNC 制造

决策。Alizadeh Kolagar 等人 [22] 把深度强化学习与捷度有界轨迹生成器结合，说明学习动作仍需要显式运动学约束来保证可执行性。现有方法已经分别提供了学习决策、前瞻感知和约束执行基础，面向长短直线与圆弧交加的混合刀具路径，仍需要把三者统一到同一运动规划闭环中。

因此，本文提出一种基于可学习前瞻与捷度约束的强化学习运动规划方法。为区别于直接神经控制方法（NNC），本文将该框架称为 J-NNC（Jerk-constrained Neural Numerical Controller）。本文将混合路径跟踪建模为允差带内的受约束序列决策问题，使策略在同一闭环中输出转向、进给与前瞻距离调节动作，并由运动学约束模块将约束前控制量投影为满足速度、加速度与捷度约束的插补控制量。传统串行式运动规划框架与 J-NNC 端到端运动规划框架的差异如图 1 所示。本文的主要贡献如下：

1. 构建结构化的状态表达，将实时运动学状态、拐角信息和多尺度前瞻信息统一为策略输入；
2. 将前瞻距离建模为可学习动作，使策略能够主动调节几何感知尺度，在直线进给、接近拐角、过弯和离开拐角阶段获得不同的感知范围；
3. 将可解释的运动学约束投影层嵌入策略执行过程，把策略输出的转向和进给意图转换为满足速度、加速度与捷度约束的安全插补命令。

本文余下内容安排如下：第二章给出问题定义与约束建模；第三章介绍所提出的方法；第四章给出实验设置、评价指标与结果分析；第五章给出局限性分析与未来展望。

## 2. 问题定义与约束建模

本章给出与本文方法直接相关的任务定义、几何约束与执行约束，为后续方法部分提供必要的形式化基础。


### 2.1. 刀具路径与几何可行域

给定由 CAM 系统生成的离散刀位点序列

$$P_{raw} = \{p_1, p_2, \dots, p_N\}, \quad (1)$$

### a) Traditional Serial Plannin


a.1 G-Code Input




a.2 Path smoothing



a.3 Velocity planning




a.4 Interpretation




a.5 Servo command

### b) J-NNC end-to-end Planning

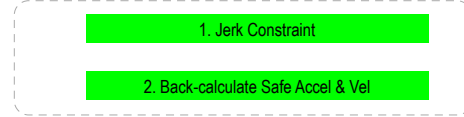
b.1 G-Code Input



b.2 PPO Agent



b.3 Kinematic Constraint Module



b.4 Safe Servo Command

图 1: 传统串行式运动规划与 J-NNC 运动规划框架对比。J-NNC 表示 Jerk-constrained Neural Numerical Controller，即带捷度约束动作投影的神经网络数控运动规划器。

其中  $p_i \in \mathbb{R}^2$  表示插补平面内的参考点。设轮廓允差为  $\varepsilon$ ，则参考路径两侧各偏置  $\varepsilon/2$  后可得到一条允许策略局部偏离的几何可行域：

$$\Omega = \{x \mid d(x, P_{raw}) \leq \varepsilon/2\}, \quad (2)$$

式中  $d(x, P_{raw})$  为点  $x$  到参考路径的最小距离。该定义意味着允许策略在允差带内进行局部几何重分配，以换取更平滑的拐角通过过程，不是严格贴近原始轨迹。




图 2: 参考路径与轮廓允差带构成的几何可行域。

为便于在闭环决策中感知局部几何，我们进一步对参考路径进行弧长参数化，并在当前投影弧长  $\ell_t$  附近提取法向误差、切向方向、到下一拐角距离以及下一拐角转角等量。这些量既参与状态构造，也参与奖励加权与拐角模式判定。

## 2.2. 受约束动作决策表述

在每个插补周期  $\Delta t$  内，策略接收当前状态  $s_t$  并输出归一化动作  $a_t^\pi$ 。运动学约束模块 (kinematic constraint module, KCM) 输出的执行控制量作用于环境后，环境更新位置、姿态及运动学状态，并返回即时奖励  $r_t$ 。因此，本文任务可以写成

一个受约束的序列决策问题：

$$\max_{\pi} \mathbb{E}_{\pi} \left[ \sum_{t=0}^T \gamma^t r_t \right], \quad (3)$$

同时满足几何约束

$$x_t \in \Omega, \quad (4)$$

以及执行侧运动学约束

$$|v_t| \leq V_{\max}, \quad |a_t| \leq A_{\max}, \quad |j_t| \leq J_{\max}, \quad (5)$$

$$|\omega_t| \leq \Omega_{\max}, \quad |\dot{\omega}_t| \leq A_{\max}^{\omega}, \quad |\ddot{\omega}_t| \leq J_{\max}^{\omega}. \quad (6)$$

其中  $v_t, a_t, j_t$  分别表示线速度、线加速度与线捷度， $\omega_t, \dot{\omega}_t, \ddot{\omega}_t$  分别表示角速度、角加速度与角捷度。

### 3. 方法

#### 3.1. 总体框架

本文将混合刀具路径运动规划表述为强化学习框架下的闭环决策过程。该过程中，策略网络作为智能体，带有轮廓允差和运动学约束的刀具路径仿真系统作为环境。在每个插补周期内，环境根据当前执行位置、运动学状态、局部拐角信息和前方几何信息构造状态  $s_t$ ；策略  $\pi_{\theta}$  根据  $s_t$  输出动作  $a_t$ ，用于描述当前周期的转向、进给和前瞻距离调节意图；动作经 KCM 修正后作用于环境，环境更新到下一状态  $s_{t+1}$ ，并根据路径进度、轮廓误差和运动平滑性返回奖励  $r_t$ 。训练阶段通过奖励反馈更新策略参数，使策略逐步学习在允差带内完成轨迹平滑、速度规划和运动学约束满足的控制规律。

本文方法的总体框架如图 3 所示。给定参考路径与轮廓允差，系统首先在环境侧完成路径投影、拐角扫描与前瞻几何提取，构造当前时刻的结构化状态向量；随后，策略网络输出归一化动作，其中转向分量与进给分量被映射为约束前运动控制量  $(\omega_t^{pre}, v_t^{pre})$ ，前瞻分量被映射为当前前瞻距离  $L_t$ ；最后，KCM 根据上一时刻的速度、加速度和捷度状态，对  $(\omega_t^{pre}, v_t^{pre})$  进行在线约束投影，得到满足速度、加速

度与捷度限制的执行控制量  $(\omega_t, v_t)$ 。执行结果反过来更新当前位置、运动学量、拐角相位与前瞻观测，并在训练阶段通过奖励信号参与策略更新，形成完整的强化学习运动规划闭环。




图 3: 本文方法的总体闭环框架。

### 3.2. 状态设计

本文采用一种分层的结构化状态表示：

$$s_t = [s_t^{\text{core}}, s_t^{\text{corner}}, s_t^{\text{preview}}]. \quad (7)$$

其中  $s_t^{\text{core}}$  描述当前时刻的局部跟踪与运动学状态， $s_t^{\text{corner}}$  描述当前路径段与下一拐角之间的关系， $s_t^{\text{preview}}$  描述前方若干距离处的几何变化趋势。

(1) 核心状态  $s_t^{\text{core}}$ . 核心状态采用 8 维构造：

$$s_t^{\text{core}} = [\bar{e}_t, \bar{e}_{n,t}, \bar{\tau}_t, \bar{v}_t, \bar{a}_t, \bar{\omega}_t, \rho_t, \bar{d}_{c,t}], \quad (8)$$

其中  $\bar{e}_t$  为归一化轮廓误差， $\bar{e}_{n,t}$  为带符号法向误差， $\bar{\tau}_t$  为当前航向与局部切向方向之间的归一化夹角误差， $\bar{v}_t$ 、 $\bar{a}_t$ 、 $\bar{\omega}_t$  分别为归一化线速度、线加速度和角速度， $\rho_t \in [0, 1]$  为路径整体进度， $\bar{d}_{c,t}$  为到下一拐角距离的归一化量。

(2) 拐角感知状态  $s_t^{corner}$ . 拐角感知状态构造为 4 维特征:

$$s_t^{corner} = [\bar{\phi}_t, \sigma_t, m_t, \sigma_t \bar{e}_{n,t}], \quad (9)$$

其中  $\bar{\phi}_t$  为下一拐角转角的归一化值,  $\sigma_t \in \{-1, 0, 1\}$  表示拐角转向符号,  $m_t \in \{0, 1\}$  表示是否处于拐角影响区间,  $\sigma_t \bar{e}_{n,t}$  则给出了相对于转向内侧或外侧的带符号位置关系。

(3) 前瞻观测  $s_t^{preview}$ . 本文沿参考路径弧长方向设置若干前瞻尺度  $\{\lambda_k\}_{k=1}^{N_L}$ 。记当前执行点在参考路径上的投影弧长坐标为  $\ell_t$ , 第  $k$  个前瞻尺度对应的前方观测点定义为

$$q_t^{(k)} = P_{raw}(\ell_t + \lambda_k L_t), \quad k = 1, \dots, N_L, \quad (10)$$

其中  $\lambda_k$  为尺度系数,  $L_t$  为当前周期采用的基础前瞻距离。由此, 近、中、远前瞻点均沿参考路径弧长方向确定, 而不是由当前执行方向上的射线交点确定。随后在每个尺度上提取前方观测点相对于当前切向的角度变化和距离比例:

$$s_t^{preview} = [\Delta\theta_t^{(1)}, \bar{d}_t^{(1)}, \dots, \Delta\theta_t^{(N_L)}, \bar{d}_t^{(N_L)}]. \quad (11)$$

其中  $\Delta\theta_t^{(k)}$  表征第  $k$  个前瞻尺度上的方向变化趋势,  $\bar{d}_t^{(k)}$  表征当前位置到该前瞻点的归一化距离。当前实现中, 主配置采用 3 个前瞻尺度。

### 3.3. 动作空间与运动学约束模块

策略网络在每个周期输出归一化动作

$$a_t^\pi = [u_{\theta,t}, u_{v,t}, u_{L,t}], \quad (12)$$

其中  $u_{\theta,t} \in [-1, 1]$  表示转向控制的归一化动作分量,  $u_{v,t} \in [0, 1]$  表示进给控制的归一化动作分量,  $u_{L,t} \in [0, 1]$  表示前瞻距离调节分量。设前瞻距离允许范围为  $[L_{\min}, L_{\max}]$ , 则其物理量映射为

$$L_t = L_{\min} + u_{L,t}(L_{\max} - L_{\min}). \quad (13)$$

策略输出首先被映射为物理空间中的约束前运动控制量:

$$\omega_t^{pre} = u_{\theta,t} \Omega_{\max}, \quad v_t^{pre} = u_{v,t} V_{\max}. \quad (14)$$



前瞻距离  $L_t$  直接参与局部参考方向与前瞻几何的计算。随后, KCM 根据上一时刻运动学状态对  $(\omega_t^{pre}, v_t^{pre})$  进行约束投影。以线速度通道为例, 设上一周期的线速度和线加速度分别为  $v_{t-1}$  与  $a_{t-1}$ , 则有

$$a_t^{pre} = \frac{v_t^{pre} - v_{t-1}}{\Delta t}, \quad (15)$$

$$j_t^{pre} = \frac{a_t^{pre} - a_{t-1}}{\Delta t}. \quad (16)$$

KCM 首先对约束前捷度进行裁剪:

$$j_t = \text{clip}(j_t^{pre}, -J_{\max}, J_{\max}), \quad (17)$$

再由此反算本周期可实现的加速度与速度:

$$a_t = \text{clip}(a_{t-1} + j_t \Delta t, -A_{\max}, A_{\max}), \quad (18)$$

$$v_t = \text{clip}\left(v_{t-1} + a_{t-1} \Delta t + \frac{1}{2} j_t \Delta t^2, 0, V_{\max}\right). \quad (19)$$

角速度通道采用完全相同的约束流程。得到的  $(\omega_t, v_t)$  作为环境执行控制量。

本文还定义 KCM 干预度:

$$\eta_t = \frac{|v_t - v_t^{pre}|}{V_{\max}} + \frac{|\omega_t - \omega_t^{pre}|}{\Omega_{\max}}. \quad (20)$$

该量不参与主优化目标, 用于结果分析中的辅助指标。

### 3.4. 奖励设计

即时奖励写为

$$r_t = r_t^{prog} + r_t^{track} + r_t^{dir} + r_t^{smooth}. \quad (21)$$

(1) 进度奖励. 进度奖励定义为

$$r_t^{prog} = w_p \max(0, \rho_t - \rho_{t-1}), \quad (22)$$

其中  $\rho_t$  为整体路径进度。

(2) 轮廓误差项. 轮廓误差项定义为

$$\phi_e(e_t) = \begin{cases} 0, & |e_{n,t}| \leq \delta_t, \\ \left(\frac{|e_{n,t}| - \delta_t}{\varepsilon/2}\right)^2, & |e_{n,t}| > \delta_t, \end{cases} \quad (23)$$

并定义

$$r_t^{track} = -w_e(c_t) \phi_e(e_t). \quad (24)$$

其中  $\delta_t$  为容许带内的松弛边界,  $c_t \in [0, 1]$  为局部拐角强度. 本文将二者定义为

$$\delta_t = \kappa_\delta \frac{\varepsilon}{2} \mathbf{1}(m_t = 1), \quad (25)$$

$$c_t = \text{clip} \left( (1 - \alpha_c) c_{t-1} + \alpha_c \frac{|\Delta \theta_t^{(N_L)}|}{\theta_0}, 0, 1 \right), \quad (26)$$

其中  $\kappa_\delta$  为误差松弛比例,  $m_t$  表示是否处于拐角影响区间,  $\Delta \theta_t^{(N_L)}$  为最远尺度前瞻方向变化,  $\theta_0$  为局部拐角强度归一化角度,  $\alpha_c = 1/T_c$  为指数滑动平均系数. 当前主实验采用  $\kappa_\delta = 0$ , 因此轮廓误差项不设置额外死区;  $c_t$  仍用于动态调节跟踪和平滑权重.

(3) 方向一致性项. 方向一致性项定义为

$$r_t^{dir} = -w_\tau |\tau_t|, \quad (27)$$

其中  $\tau_t$  为当前航向与局部参考方向之间的夹角误差.

(4) 平滑性项. 平滑性项定义为

$$r_t^{smooth} = -w_s(c_t) \psi_t, \quad (28)$$

其中  $\psi_t$  可取线捷度、角加速度或角捷度的归一化量;  $w_s(c_t)$  采用随局部拐角强度动态变化的权重. 一个常用实现为

$$w_s(c_t) = w_s^0 c_t^\gamma, \quad \gamma > 1, \quad (29)$$

其中  $w_s(c_t)$  随  $c_t$  增大而增大.

## 4. 实验设计与结果

本节通过仿真实验评价本文方法在不同几何路径下的运动规划效果。实验重点考察三方面内容：路径是否能够稳定推进，轨迹是否能够在允差带内形成合理过渡，以及执行控制量是否满足速度、加速度和捷度约束。实验包括主对照实验和消融实验。主对照实验比较 J-NNC 与神经网络控制器（neural network controller, NNC）方法，消融实验分别改变前瞻距离、KCM、前瞻观测和奖励调度，用于分析各模块对结果的影响。

### 4.1. 实验设置

实验测试路径选取正方形、圆形与蝴蝶形三类代表性路径。圆形路径具有连续转向特征，主要用于观察策略在连续曲率条件下的速度保持和误差控制。正方形路径包含典型尖角，主要用于观察策略在进入拐角、通过拐角和离开拐角时的减速、转向和再加速过程。蝴蝶形路径包含局部曲率变化和形状变化，主要用于观察策略在复杂几何路径上的连续推进能力和轨迹控制能力。

主对照实验比较 J-NNC 和 NNC 方法。J-NNC 采用结构化状态表示、可学习前瞻距离、KCM 约束执行和拐角感知奖励。NNC 方法参照 Li 等 [20] 提出的直接神经控制思路构造，采用直接神经控制结构，策略输出直接进入环境执行。两种方法的比较重点是路径推进能力、轮廓误差和运动学约束满足情况。

消融实验以本文方法为基础进行修改。固定前瞻配置将可学习前瞻距离替换为固定前瞻长度；无 KCM 配置移除执行层运动学约束投影，使策略输出直接进入环境执行；无前瞻观测配置移除多尺度前方几何输入；无直线/拐角双奖励配置取消直线段与拐角段的差异化奖励调度。通过这些配置，可以分别观察前瞻距离、执行约束、前方几何信息和奖励结构对实验结果的影响。

实验评价采用各配置导出的 best rollout 作为统计对象，不再对多次 evaluation episode 取平均。指标包括终止状态、最终进度、最大轮廓误差、线捷度最大相对超限和终止时间。终止状态和最终进度反映路径推进情况，最大轮廓误差反映轨迹偏离参考路径的程度，线捷度最大相对超限反映执行控制量是否满足捷度约束，终止时间由 best rollout 终止步数与插补周期相乘得到。由于本文研究的是受约束运动规划，后续分析同时考虑效率、误差和动态可执行性。

#### 4.2. 主对照实验结果

本小节给出本文方法与 NNC 方法在三条代表性路径上的对比结果。表 1 汇总了各方法的终止状态、最终进度、最大轮廓误差、线捷度最大相对超限和终止时间等指标。

表 1: 本文最终方法与基线策略在代表性路径 best rollout 上的对比结果。

| 路径        | 指标        | 本文最终方法  | NNC 基线    |
|-----------|-----------|---------|-----------|
| square    | 终止状态      | success | success   |
|           | 最终进度      | 1.000   | 1.000     |
|           | 最大轮廓误差    | 0.834   | 0.676     |
|           | 线捷度最大相对超限 | 0.000   | 3199.000  |
|           | 终止时间 (s)  | 12.192  | 8.672     |
| circle    | 终止状态      | success | max_steps |
|           | 最终进度      | 1.000   | 0.990     |
|           | 最大轮廓误差    | 0.096   | 6.259     |
|           | 线捷度最大相对超限 | 0.000   | 3199.000  |
|           | 终止时间 (s)  | 9.117   | 60.000    |
| butterfly | 终止状态      | success | success   |
|           | 最终进度      | 1.000   | 1.000     |
|           | 最大轮廓误差    | 0.745   | 0.207     |
|           | 线捷度最大相对超限 | 0.000   | 3199.000  |
|           | 终止时间 (s)  | 10.480  | 5.807     |

表 1 显示，本文方法在 square、circle 和 butterfly 三条路径上均达到成功终止，NNC 方法在 square 和 butterfly 上成功终止，但在 circle 路径上达到步数上限。进

一步比较可以看到，本文方法的主要优势体现在能够满足运动学约束。本文方法在三条路径上将线速度最大相对超限控制为零，NNC 方法虽然体现出直接神经控制的进给能力，但在速度约束指标上出现明显超限。该结果说明，仅由策略直接输出控制量时，输出动作可能导致违反运动学约束；引入 KCM 后，策略输出能够被转换为满足速度、加速度和速度限制的执行控制量。

从不同路径看，圆形路径主要反映连续转向条件下的控制效果。表 1 中圆形路径的结果表明，本文方法能够成功终止，并将轮廓误差和速度约束控制在合理范围内；NNC 方法在该路径上达到步数上限。正方形路径包含尖角和闭合终点，两种方法都能够完成路径，但二者差异主要出现在拐角附近的轨迹处理和速度约束上。NNC 方法的轨迹更贴近原始折线，方向变化更集中；本文方法在允差带内形成局部过渡，并通过 KCM 限制执行控制量。蝴蝶形路径包含更复杂的曲率变化，NNC 方法在部分效率或误差指标上可能具有数值优势，但其速度超限说明该轨迹难以直接作为满足约束的插补轨迹。相比之下，本文方法用更保守的执行过程满足了运动学约束。

图 4 给出了三条路径上的轨迹对比。




图 4: 主方法与基线方法在代表性路径场景下的轨迹对比。

图 4中，本文方法生成的轨迹位于允差带内，并没有完全贴合参考折线。圆形路径中，本文方法的轨迹连续推进，速度变化较平稳。正方形路径中，本文方法在

角点附近形成局部过渡。蝴蝶形路径中，本文方法在曲率变化区域产生一定偏移。上述现象说明，本文方法利用允差带进行局部轨迹调整，以减小拐角或曲率变化处的控制量突变。

正方形路径的拐角区域对比见图 5。




图 5: 主方法与 NNC 方法在正方形路径拐角区域的局部放大轨迹对比。

图 5显示，本文方法在接近角点前开始改变方向，在允差带内形成连续过渡轨迹。NNC 方法的轨迹更接近原始折线，方向变化集中在拐角点附近。该现象与表 1中的捷度结果一致。直接执行策略输出时，拐角处容易出现较大的动态变化；经过 KCM 约束后，本文方法能够在转向过程中满足捷度限制。

本文方法在代表性 best rollout 上的轮廓误差、速度与线捷度归一化时序如图 6所示。




图 6: 本文最终方法在选定代表性 best rollout 上的轮廓误差、速度与线捷度归一化时序。

图 6中，轮廓误差峰值主要出现在拐角阶段，说明策略在过弯时使用了允差带中的空间。速度曲线反映了进入拐角、通过拐角和离开拐角时的调速过程。当前历史 best rollout 的轨迹 CSV 未直接保存环境内部逐步捷度字段，因此图中给出由同一 best rollout 的速度记录经 KCM 边界复核得到的窗口峰值  $|j|/j_{max}$  曲线；该曲线不超过 1，结合表 1可知，启用 KCM 后线捷度最大相对超限为零。

综合表 1与图 4至图 6可以看出，本文方法在三类路径上均完成 best rollout，并能够在直线高速进给和拐角处的允差带内形成局部平滑轨迹。对于正方形尖角和蝴蝶形混合曲率区域，本文方法通过适当的轨迹平滑和 KCM 约束，使拐角或曲率变化处的执行控制量保持在运动学边界内。NNC 方法体现出直接神经控制的推进能力，但缺少显式约束处理时，不具备动态可执行性。



### 4.3. 消融实验结果

本小节给出可学习前瞻距离、KCM、前瞻观测以及直线/拐角双奖励等模块的消融结果。表 2按路径汇总不同配置 best rollout 的终止状态、最终进度、最大轮廓误差、线捷度最大相对超限和终止时间。

表 2: 结构化消融路径级 best rollout 结果汇总。

| 模型配置      | 路径        | 终止状态    | 最终进度  | 最大轮廓误差 | 线捷度最大相对超限 | 终止时间 (s) |
|-----------|-----------|---------|-------|--------|-----------|----------|
| 本文最终方法    | square    | success | 1.000 | 0.834  | 0.000     | 12.192   |
| 本文最终方法    | circle    | success | 1.000 | 0.096  | 0.000     | 9.117    |
| 本文最终方法    | butterfly | success | 1.000 | 0.745  | 0.000     | 10.480   |
| 固定前瞻      | square    | success | 1.000 | 0.699  | 0.000     | 8.680    |
| 固定前瞻      | circle    | success | 1.000 | 0.046  | 0.000     | 4.804    |
| 固定前瞻      | butterfly | success | 1.000 | 0.638  | 0.000     | 5.049    |
| 无 KCM     | square    | success | 1.000 | 0.722  | 3199.000  | 10.301   |
| 无 KCM     | circle    | success | 1.000 | 0.061  | 3199.000  | 5.926    |
| 无 KCM     | butterfly | success | 1.000 | 0.707  | 3199.000  | 7.446    |
| 无前瞻观测     | square    | success | 1.000 | 0.805  | 0.000     | 8.151    |
| 无前瞻观测     | circle    | success | 1.000 | 0.077  | 0.000     | 4.573    |
| 无前瞻观测     | butterfly | success | 1.000 | 0.820  | 0.000     | 6.044    |
| 无直线/拐角双奖励 | square    | success | 1.000 | 0.824  | 0.000     | 15.132   |
| 无直线/拐角双奖励 | circle    | success | 1.000 | 0.030  | 0.000     | 10.388   |
| 无直线/拐角双奖励 | butterfly | success | 1.000 | 0.918  | 0.000     | 9.623    |

表 2显示，各消融配置在三条路径的 best rollout 上均能成功终止，但终止时间、轮廓误差和捷度约束满足情况存在差异。固定前瞻配置反映了前瞻距离在线调节的影响，无前瞻观测配置反映了多尺度几何信息的影响，无直线/拐角双奖励配置反映了阶段化奖励调度的影响，无 KCM 配置用于分析执行层约束投影的作用。除无 KCM 配置外，其余配置均启用 KCM，因此线捷度最大相对超限为零。

本文最终方法与无 KCM 配置在相同代表性路径上的线捷度对比如图 7所示。

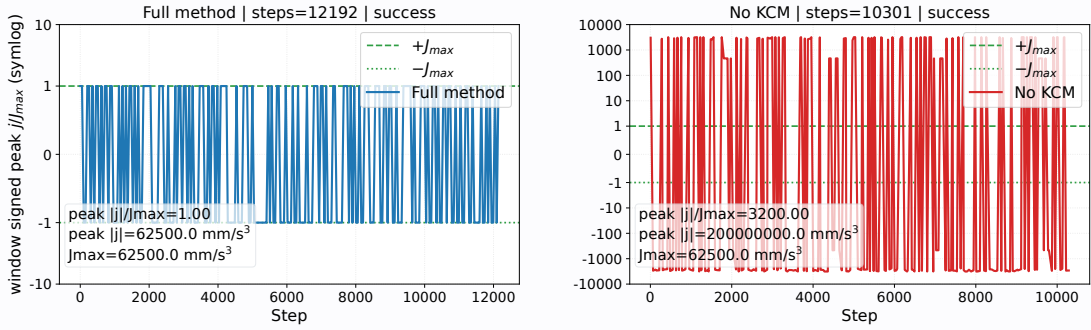


图 7: 本文最终方法与无 KCM 消融在相同代表性路径上的线捷度与捷度约束对比。

图 7 显示，本文最终方法的线捷度被限制在  $J_{\max}$  边界内，无 KCM 配置在相同路径上出现高幅值捷度尖峰。该结果说明，用时较短或轮廓误差较小并不一定代表轨迹可执行。KCM 对本文方法是必要模块，其作用是将策略输出转化为满足速度、加速度与捷度约束的执行控制量。

固定前瞻配置用于观察前瞻距离调节分量的作用。该配置保留前方几何感知结构，采用固定前瞻长度进行决策。结合表 2 可见，固定前瞻在三条路径上均成功终止，且部分路径终止时间较短。可学习前瞻距离为策略提供了在线调节感知尺度的自由度，同时也增加了动作空间维度，其效果与路径复杂度、奖励权重和 KCM 干预程度相关。当前结果说明，前瞻距离动作的参数化方式仍需要进一步调整，使其更稳定地服务于提前调速和拐角预处理，而不能仅以终止时间单项判断其作用。

无前瞻观测配置用于观察多尺度前方几何信息的作用。该配置保留可学习前瞻距离和 KCM 约束执行，移除多尺度前瞻观测状态。结合表 2 可见，局部状态和拐角感知能够支撑三条路径的基本推进，但不同路径上的终止时间和轮廓误差发生变化。多尺度前瞻观测为策略提供更完整的前方几何趋势信息，主要作用于复杂混合路径中的提前减速、提前转向和速度衔接。该模块的收益需要在更长路径、更密集拐角和更复杂曲率变化中进一步验证。

无直线/拐角双奖励配置用于考察阶段化奖励的作用。该配置采用统一奖励权重处理直线进给、进入拐角、过弯和离开阶段。结合表 2 可见，移除该模块后跨路径完成稳定性下降。直线段主要要求稳定进给和方向一致，拐角段主要要求控制误差、降低速度变化并平滑转向。如果所有阶段使用同一奖励权重，策略在直线段和

拐角段之间切换时更容易出现不稳定行为。因此，直线/拐角双奖励能够使策略在不同几何阶段采用不同的控制方式。

综合表 2 与图 7 可以看出，KCM 主要保证执行轨迹的动态可行性，直线/拐角双奖励主要影响不同几何阶段的行为稳定性，可学习前瞻距离与多尺度前瞻观测主要提供前方几何感知与在线调节能力。当前结果同时表明，square 闭合路径虽然能够成功终止，但终止时间和拐角后速度衔接仍是影响实验效率的重要因素，需要在后续优化中单独处理。

#### 4.4. 本节小结

主对照实验表明，本文方法在三条代表性路径上均能够形成有效轨迹，并且能够将执行控制量限制在给定运动学边界内。与 NNC 方法相比，本文方法的主要优势是动态可执行性更强，在拐角和曲率变化区域能够避免捷度超限。

消融实验表明，KCM 是保证约束满足的关键模块，直线/拐角双奖励有助于提高跨路径稳定性。可学习前瞻距离和多尺度前瞻观测提供了几何感知和在线调节能力。总体来看，本文方法能够在保持路径推进的同时满足运动学约束，适合用于强调动态可执行性的数控运动规划场景。

### 5. 局限性分析与未来展望

本文方法仍有若干不足。首先，可学习前瞻距离虽然增加了在线调节自由度，但在当前实验中，其优势尚未稳定转化为更短用时，说明前瞻距离分量的参数化方式仍需改进。其次，方法在不同几何路径上的表现还不完全均衡。对于连续曲率路径，策略较容易形成稳定的速度调节；对于含尖角或混合曲率变化的路径，阶段切换、终点收敛和局部过弯仍是主要难点。最后，KCM 能够保证执行控制量满足运动学约束，但也可能带来更保守的速度变化，说明策略本体尚需进一步学习贴合约束边界的控制规律。

后续工作将从三方面展开。第一，改进动作空间中前瞻距离分量的参数化方式，例如采用残差式、分段式或与拐角相位相关的前瞻参数化，以降低学习难度并减少与前瞻观测之间的冗余。第二，细化拐角阶段建模，重点处理尖角进入、过弯、离开和终点停止等局部过程，提高复杂路径下的完成率与速度衔接稳定性。第三，扩

大测试路径集合，并进一步引入伺服滞后、轴向约束和实机加工条件，使仿真中的允差带利用、时间效率和捷度约束评价逐步接近实际 CNC 运动规划需求。

## 附录

### PPO 训练设置

策略采用 Proximal Policy Optimization。Actor 为三层共享多层感知机，隐藏层宽度依次为 256, 128, 64，激活函数为 ELU，每层后使用 LayerNorm，输出头给出 3 维动作的均值和标准差；其中转向动作均值经  $\tanh$  限制到  $[-1, 1]$ ，进给和前瞻动作均值经  $\text{sigmoid}$  限制到  $[0, 1]$ ，标准差经  $\text{softplus}$  后加  $10^{-3}$ 。Critic 为 256, 128, 64, 1 结构，使用 ELU、LayerNorm 和 0.1 dropout。

表 3: PPO 超参数与训练协议。

| 参数               | 取值                   |
|------------------|----------------------|
| Actor 学习率        | $3.0 \times 10^{-4}$ |
| Critic 学习率       | $1.5 \times 10^{-4}$ |
| 折扣因子 $\gamma$    | 0.99                 |
| GAE 参数 $\lambda$ | 0.95                 |
| PPO clip 系数      | 0.1                  |
| 每次更新 epoch 数     | 8                    |
| 熵系数              | 0.01                 |
| 梯度裁剪             | 0.5                  |

---

**Algorithm 1** KCM 约束投影过程

---

**Require:** 策略输出  $a_t^\pi = [u_{\theta,t}, u_{v,t}, u_{L,t}]$ ; 上一时刻运动学状态  $(v_{t-1}, a_{t-1}, \omega_{t-1}, \alpha_{t-1})$

**Ensure:** 执行控制量  $(\omega_t, v_t)$  及更新后的运动学状态

- 1: 将  $u_{\theta,t}$  与  $u_{v,t}$  映射为约束前运动控制量  $(\omega_t^{pre}, v_t^{pre})$
  - 2: 将  $u_{L,t}$  映射为当前前瞻距离  $L_t$
  - 3: 根据  $v_t^{pre}$  与  $v_{t-1}$  计算约束前线加速度  $a_t^{pre}$
  - 4: 根据  $a_t^{pre}$  与  $a_{t-1}$  计算约束前线捷度  $j_t^{pre}$
  - 5: 对  $j_t^{pre}$  进行裁剪, 得到满足上限的  $j_t$
  - 6: 由  $j_t$  反算线加速度  $a_t$ , 并执行加速度裁剪
  - 7: 由  $(v_{t-1}, a_{t-1}, j_t)$  积分得到本周期线速度  $v_t$
  - 8: 对角速度通道采用同构流程, 得到约束后的  $\omega_t$
  - 9: 返回执行控制量  $(\omega_t, v_t)$  及相应更新后的运动学状态
-

## References

- [1] Yuwen Sun, Jinjie Jia, Jinting Xu, Mansen Chen, and Jinbo Niu. Path, feedrate and trajectory planning for free-form surface machining: A state-of-the-art review. *Chinese Journal of Aeronautics*, 35(8):12–29, 2022.
- [2] A. C. Lee, M. T. Lin, Y. R. Pan, and W. Y. Lin. The feedrate scheduling of NURBS interpolator for CNC machine tools. *Computer-Aided Design*, 43(6):612–628, 2011.
- [3] Bingcai Wu, Junyan Ma, Lutao Wei, Xiaoping Liao, and Juan Lu. NURBS interpolator with scheduling scheme combining cubic and quartic S-shaped feedrate profiles under drive and chord error constraints. *Computer-Aided Design*, 152:103380, 2022.
- [4] Hexiong Li, Xin Jiang, Guanying Huo, Cheng Su, Shiwei Zhou, Bolun Wang, Yifei Hu, and Zhiming Zheng. An integrated trajectory smoothing method for lines and arcs mixed toolpath based on motion overlapping strategy. *Journal of Manufacturing Processes*, 95:242–265, 2023.
- [5] Yifei Hu, Xin Jiang, Guanying Huo, Cheng Su, Hexiong Li, Li-Yong Shen, and Zhiming Zheng. Enhancing five-axis CNC toolpath smoothing: Overlap elimination with asymmetrical B-splines. *CIRP Journal of Manufacturing Science and Technology*, 52:36–57, 2024.
- [6] Kaan Erkorkmaz and Yusuf Altintas. High speed CNC system design. part I: jerk limited trajectory generation and quintic spline interpolation. *International Journal of Machine Tools and Manufacture*, 41(9):1323–1345, 2001.
- [7] Yong Zhang, Hui Zhang, Jiadong Shi, Jiali Jiang, and Mingyong Zhao. Development of an adaptive-feedrate planning and iterative interpolator for parametric toolpath with normal jerk constraint. *International Journal of Precision Engineering and Manufacturing*, 22:73–81, 2021.

- [8] Guangwen Yan, Desheng Zhang, Jinting Xu, and Yuwen Sun. Corner smoothing for CNC machining of linear tool path: A review. *Journal of Advanced Manufacturing Science and Technology*, 3(2):2023001, 2023.
- [9] Huan Zhao, Limin Zhu, and Han Ding. A real-time look-ahead interpolation methodology with curvature-continuous B-spline transition scheme for CNC machining of short line segments. *International Journal of Machine Tools and Manufacture*, 65:88–98, 2013.
- [10] De-Ning Song, Jian-Wei Ma, Yu-Guang Zhong, and Jian-Jun Yao. Global smoothing of short line segment toolpaths by control-point-assigning-based geometric smoothing and FIR filtering-based motion smoothing. *Mechanical Systems and Signal Processing*, 160:107908, 2021.
- [11] S. Sun, P. Zhao, T. Zhang, B. Li, and D. Yu. Smoothing interpolation of five-axis tool path with less feedrate fluctuation and higher computation efficiency. *Journal of Manufacturing Processes*, 109:669–693, 2024.
- [12] De-Ning Song, Yu-Guang Zhong, and Jian-Wei Ma. Look-ahead-window-based interval adaptive feedrate scheduling for long five-axis spline toolpaths under axial drive constraints. *Proceedings of the Institution of Mechanical Engineers, Part B: Journal of Engineering Manufacture*, 234(13):1656–1670, 2020.
- [13] Haiming Zhang, Jianzhong Yang, Wanqiang Zhu, Chenglei Zhang, and Zifang Hu. Jerk-constrained feedrate scheduling for CNC machining based on constraint-guided sampling. *The International Journal of Advanced Manufacturing Technology*, 2026.
- [14] Yunan Wang, Chuxiong Hu, Jichuan Yu, Shize Lin, Zhao Jin, and Jizhou Yan. Jerk-limited oscillation-free feedrate scheduling under non-stationary boundary conditions. In *2025 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM)*, pages 1–6, 2025.



- [15] Mingxi Zhong, Yanyang Liang, Wenxuan Xie, Wei Cui, Hongfei Lv, and Dongzhou Zhong. Real-time dynamic look-ahead trajectory planning for industrial robots based on visual feedback. *The International Journal of Advanced Manufacturing Technology*, 140:6045–6063, 2025.
- [16] Tu-Hoa Pham, Giovanni De Magistris, and Ryuki Tachibana. OptLayer – practical constrained optimization for deep reinforcement learning in the real world. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6236–6243. IEEE, 2018.
- [17] Mohammed Alshiekh, Roderick Bloem, Rüdiger Ehlers, Bettina Könighofer, Scott Niekum, and Ufuk Topcu. Safe reinforcement learning via shielding. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1):2669–2678, 2018.
- [18] Richard Cheng, Gábor Orosz, Richard M. Murray, and Joel W. Burdick. End-to-end safe reinforcement learning through barrier functions for safety-critical continuous control tasks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33(01):3387–3395, 2019.
- [19] Kim Peter Wabersich and Melanie N. Zeilinger. A predictive safety filter for learning-based control of constrained nonlinear dynamical systems. *Automatica*, 129:109597, 2021.
- [20] Bingran Li, Hui Zhang, Peiqing Ye, and Jinsong Wang. Trajectory smoothing method using reinforcement learning for computer numerical control machine tools. *Robotics and Computer-Integrated Manufacturing*, 61:101847, 2020.
- [21] Vladimir Samsonov, Chrismarie Enslin, Hans-Georg Köpken, Schirin Bär, Daniel Lütticke, and Tobias Meisen. Deep representation learning and reinforcement learning for workpiece setup optimization in CNC milling. *Production Engineering*, 17(6):847–859, 2023.

- [22] Seyed Adel Alizadeh Kolagar, Mehdi Heydari Shahna, and Jouni Mattila. Combining deep reinforcement learning with a jerk-bounded trajectory generator for kinematically constrained motion planning. In *2025 European Control Conference (ECC)*, pages 2507–2514. IEEE, 2025.